AquaDiag：面向低资源水产的多模态诊断对话基准——主动追问、合规与病灶识别

Anonymous COLING/Findings submission

Paper ID *****

Abstract

水产疾病诊断是一个高风险、强合规、低资源的多模态任务：养殖户通常只提供一张现场照片和一句口头主诉，而合格的诊断需要先追问关键临床字段、信息足够才下结论、无法确诊时明确拒答并建议送检，且全程不得给出具体用药剂量。本文构建 AquaDiag，首个面向低资源水产的多模态诊断对话基准，将诊断任务显式解耦为**病灶/体征识别**（确定性）与**病种诊断**（不确定性，含合规红线与拒答判断）两个子任务，覆盖 207 个病例、5 个病种，提供黄金追问序列、受控病灶本体（13 种病灶类型 × 10 个部位）与 6+1 项指标。在此基准上，我们发现四个代表性视觉语言模型（GPT-5.6、Qwen3-VL-8B、Qwen3.8-27B、DeepSeek-VL2）在”该追问不追问、该拒答不拒答、违规开药”上存在系统性失败：即使对话协议已显式要求先追问、图不足则送检，四者先追问率仍仅为 0%–55.6%，拒答准确率仅为 55.6%–94.4%，而合规违规率最高达 41.5%。为修复这一问题，我们提出轻量方法 ProDiag，以”视觉显式化 + 可审计规则表 + 红线硬过滤”替代自由生成，在不进行任何训练的情况下，即达到诊断准确率 100%、合规违规率 0%、先追问率 100%、必问字段覆盖率 94.2% 与拒答准确率 100%，在全部 7 项指标上超越三个基线模型。进一步的专家标注显示，53% 的真实病灶图无法仅凭图像确定病种（爱德华氏菌病 6/6 图均需送检），印证了”病灶识别 ≠ 病种诊断”的天然分离，凸显可追溯证据与安全拒答在专业诊断中的必要性。

1. 引言

水产养殖是我国重要的农业产业，而病害是制约养殖效益与食品安全的关键因素。养殖过程中，牛蛙、鱼类等水产生物一旦发病，养殖户往往只能提供一**张现场照片和一句口头主诉**（例如”今天蛙不吃料了”），然后期待一个明确的诊断与处理方案。然而，从这样有限的输入中得出可靠诊断，本质上是一个信息严重不足的推理过程：照片只能提供表观病灶，主诉只能提供行为异常，而**水温、死亡率、粪便、是否剖检、养殖密度**等关键临床字段完全缺失。一个合格的诊断助手必须在给出结论之前，主动向养殖户追问这些缺失字段。

更复杂的是，水产诊断是一个**高风险、强合规**的任务。误诊和乱开药不仅直接造成经济损失，还涉及禁用药与处方药的食品安全红线；而”看不清就送检”是兽医执业的基本要求。这意味着一个可用的诊断模型不仅要”会追问、会诊断”，还必须”该拒答时明确拒答””全程不给出具体用药剂量”。这三个行为——**追问、拒答、合规**——共同构成了专业诊断的安全底线。

然而，我们发现现有视觉语言模型（VLM）在这三个行为上存在系统性的失败。即使对话协议已经显式地要求模型”信息不足时先追问、图片不足时明确送检”，在 207 个真实诊断病例上，四个代表性 VLM 的表现依然令人失望：先追问率仅为 0%–55.6%，该拒答时的拒答准确率仅为 55.6%–94.4%，而合规违规率最高达到 41.5%（模型直接输出药物与剂量）。更值得注意的是一种”能力互补但同样危险”的模式：诊断准确率最高的 Qwen3-VL-8B（83.1%）恰恰是违规率最高的（41.5%）；而最安全的 Qwen3.8-27B（违规 1.9%）诊断准确率却只有 72.0%。**这表明”诊断准”与”守安全”在**

当前 VLM 中难以兼得，且光靠提示词无法弥合这一鸿沟。

现有工作尚未正面解决这一组合问题。多模态问答中的澄清研究（如 ACL 2025 的 Teaching VLMs to Ask [?]）聚焦于" 问题歧义" 的消解，而非" 诊断信息不足" 的追问；医疗对话系统（如 MedDG [?]）关注文本槽位填充，缺少多模态输入与合规约束；VLM 强化后训练（如 Patho-R1 [?]、Reason-RFT [?]）致力于提升推理能力与效率，却没有把" 何时该追问、何时该拒答" 作为对齐目标。更重要的是，这些工作都没有提供一个能同时度量**追问、拒答、合规与病灶识别**的评测基准，使得" 专业诊断中的主动问询与安全拒答" 这一能力长期缺乏可复现的度量。

为填补这一空白，本文构建 AquaDiag，首个面向低资源水产的多模态诊断对话基准。AquaDiag 将诊断任务显式解耦为两个子任务：**病灶/体征识别**（确定性任务——图像中可见的病灶类型与部位，可由受控本体直接标注与评测）与**病种诊断**（不确定性任务——给定图像与多轮问诊，模型须先追问关键字段、信息足够才下诊断、无法确诊则拒答并建议送检、全程遵守合规红线）。基准包含 207 个病例、覆盖 5 个病种，提供黄金追问序列、受控病灶本体（13 种病灶类型 × 10 个部位）与 6+1 项指标。在此基础上，我们提出轻量方法 ProDiag，以" 视觉显式化 + 可审计规则表 + 红线硬过滤" 替代自由生成，在不进行任何训练的情况下，即在诊断准确率（100%）、合规违规率（0%）、先追问率（100%）、必问字段覆盖率（94.2%）与拒答准确率（100%）上全面超越三个基线 VLM，证明了**可审计的领域规则结构能够同时修复追问、合规与拒答三类行为缺陷**。

本文的主要贡献如下：

- AquaDiag **基准**：首个面向低资源水产的多模态诊断对话基准，将任务解耦为" 病灶/体征识别（确定性）" 与" 病种诊断（不确定性，含合规红线与拒答）"，提供 207 病例、6+1 指标、受控病灶本体与黄金追问序列。
- **系统性发现**：揭示三个 VLM 在" 该追问不追问、该拒答不拒答、违规开药" 上的系统性失败，并实证" 病灶识别 ≠ 病种诊断"（专家标注显示 53% 的真实病灶图无法仅凭图像确定病种，爱德华氏菌病 6/6 图均需送检）。
- ProDiag **方法**：以" 视觉显式化 + 规则表 + 红线过滤" 的轻量可审计方法，不训练即实现诊断 100% + 合规 0% + 追问 100% + 拒答 100%，为低资源专业诊断提供了一条可行且可解释的路线。

2. 相关工作

2.1. 多模态问答与主动澄清

视觉问答中的歧义与澄清是近年研究热点。Jian 等人提出 ClearVQA 基准与自动生成" 歧义–澄清" 问题对的管线，解决用户提问中" 指代不明、含义不清" 的歧义，并训练 VLM 先澄清再作答 [?]；PromptCap 则将澄清建模为任务生成问题 [?]。这些工作共同表明 VLM 天生" 爱答不爱问"。**本文的区别**在于：它们解决的是" 问题歧义"，而 AquaDiag 解决的是" 诊断信息不足"——模型需要追问的是缺失的临床字段（水温、死亡率、粪便），而非澄清指代对象；此外，我们额外叠加了**合规红线**与**拒答判断**两个维度。

2.2. 医疗/诊断对话与槽位填充

医疗对话系统长期以槽位填充方式组织问诊流程。MedDG 构建了多领域中文医疗对话数据集与槽位填充评测 [?]。这类工作聚焦于文本输入，缺少多模态图像证据，也不包含" 无法确诊即拒答" 的安全机制。**本文的区别**在于：AquaDiag 是多模态（图像 + 主诉）的，且把合规红线、拒答判断与病灶识别作为一等评测维度。

2.3. VLM 强化后训练与视觉遗忘

可验证强化学习为多模态推理提供了一致接口。GRPO 通过组内相对得分估计优势，降低对独立价值模型的依赖 [?]；Reason-RFT 与 Patho-R1 分别在通用视觉推理与病理领域展示了 VLM 后训练的可行性 [? ?]。TVC、CoFFT 等工作处理长推理中的视觉遗忘，通过在推理过程中重新注入视觉条件 [? ?]。**本文的区别**在于：我们关注的是" 何时该追问、何时该拒答" 的**行为对齐**，而非推理长度与效率；且 ProDiag 以可审计规则而非训练为主，直接证明规则结构即可修复行为缺陷。

2.4. 本文定位

与只处理文本 RAG、只优化单一视觉基准、或只做澄清的工作不同，本文首次将**主动追问**、**合规红线**、**拒答判断与病灶识别**组合为低资源专业诊断的评测基准，并以" 视觉显式化 + 规则表 + 红线过滤" 的轻量方法证明：**可审计的领域规则结构能同时修复追问、合规、拒答三类行为**。我们强调可复现边界：基线统一多轮协议、指标全自动可审计、ProDiag 不训练、病灶本体受控。

3. 方法

AquaDiag 基准将诊断任务解耦为两个子任务，ProDiag 方法以规则结构实现这两个子任务。

3.1. AquaDiag 基准

数据。AquaDiag 包含 207 个诊断病例，覆盖 5 个病种：红腿病 (30)、腐皮病 (24)、腹水病 (12)、车轮虫病 (123)、爱德华氏菌病 (18)，对应 69 张病灶图。每个病例标注主诉、黄金追问序列、病种/拒答真值、分级处理建议、合规与依据。为贴近真实养殖户的灵活表达，主诉分为**模糊/部分/详细**三档（均匀各 1/3），诊断所需的关键线索（病灶表现）置于**症状字段答案**中，仅当模型主动追问时才返回。

两个子任务。

- **任务 1 · 病灶/体征识别（确定性）**：给定图像，输出可见的病灶类型与部位，从受控病灶本体中选择。受控病灶本体含 13 种病灶类型（充血、出血、溃疡、水肿、肿大、坏死、黏液增多、白斑、褪色、变形、萎缩、脓肿、无可见病灶）× 10 个部位（皮肤、腹部、腿部、肝、肠、脾、眼、鳃、肛门、全身）。金标准由专家按本体标注，并附体征识别置信度。
- **任务 2 · 病种诊断（不确定性）**：给定图像 + 主诉 + 多轮问诊，模型须 (i) 先追问必问字段；(ii) 信息足够才下诊断；(iii) 无法确诊则拒答并建议送检；(iv) 全程遵守合规红线。必问字段按病种定义，如红腿病为 {水温、死亡率、密度、换水}，车轮虫病为 {溶氧、镜检、密度}。

指标。共 6+1 项：(1) 诊断准确率（可诊断病例中病名正确比例）；(2) 拒答准确率（必须送检病例中正确拒答比例）；(3) 先追问率 + 必问字段覆盖率；(4) 合规违规率（越界给药/剂量的比例，越低越好）；(5) 依据引用率（回答是否引用图见/关键指标）；(6) 病灶识别命中率（模型是否识别出黄金病灶类型）。

合规红线。禁用药、处方药与剂量硬过滤：若回答中出现具体药物名或剂量（如" 氟苯尼考 XX mg/L"）且未附带" 送检/咨询兽医" 提示，即判为违规。

3.2. ProDiag：轻量规则方法

ProDiag 以" 视觉显式化 + 可审计规则表 + 红线硬过滤" 替代自由生成，不进行任何训练：

1. **视觉显式化**：用 VLM 零样本看图，输出" 图见病灶" 的结构化文本。这一步把视觉证据降维为文本，后续对话依赖文本而非原始图像 token，天然抵抗视觉遗忘；且" 图见病灶" 本身即" 依据"。
2. **规则表**：由领域专家整理" 症状 → 必问字段 → 疑似病 → 分级措施 → 红线"，可审计、可追溯。
3. **信息增益追问**：从规则表的必问字段中，按信息增益排序，最多追问 3 轮。
4. **红线硬过滤**：禁用药/处方药/剂量直接拦截；对" 必须送检" 病种（如爱德华氏菌病）强制输出拒答 + 送检建议。

设计要点在于：追问、诊断、合规均由**规则约束**，模型只负责视觉理解与语言组织；因此行为可预期、可审计，不依赖模型" 自觉"。

4. 实验

4.1. 实验设置

主诉分三档。为贴近真实养殖户的灵活表达，AquaDiag 为每个病例生成三档主诉：**模糊**（仅行为描述，如" 蛙不吃料了"）、**部分**（行为 + 半句症状，如" 蛙腿有点发红"）、**详细**（行为 + 症状 + 病程），均匀各占 1/3。诊断所需的关键线索（病灶表现）主要放在**症状字段答案**中，仅当模型主动追问" 皮肤什么样子" 时才返回——模拟" 医生问诊、养殖户作答" 的真实流程。

基线：GPT-5.6、Qwen3-VL-8B、Qwen3.8-27B。统一多轮协议：第 1 轮输入图像 + 主诉，模型可追问；系统只回填模型明确询问的字段；最多 3 轮；协议显式要求" 信息不足先追问、图不足明确送检"。

ProDiag：规则版（视觉显式化 + 加权规则表 + 红线过滤），不训练。追问缺失字段（含症状），诊断信号来自" 症状答案 + 视觉"。

评测：evaluate5.py，7 项指标全自动。

表 1. 207 病例上的 7 项指标对比（%）。(1) 诊断（189 可诊断）、(2) 拒答（18 必须送检）、(3) 先追问率、(4) 缺失字段覆盖率、(5) 合规违规率（越低越好）、(6) 依据引用率、(7) 病灶识别命中率。

指标	GPT	8B	27B	DeepSeek	ProDi
(1) 诊断准确率	60.8	83.1	72.0	67.7	100
(2) 拒答准确率	88.9	83.3	55.6	94.4	100
(3) 先追问率	55.6	19.8	25.1	0.0	100
(4) 字段覆盖率	30.0	10.3	12.3	0.0	94.2
(5) 合规违规率	2.9	41.5	1.9	1.4	0
(6) 依据引用率	72.5	99.5	99.5	90.8	100
(7) 病灶识别命中率	26.6	33.3	41.1	18.4	42.0

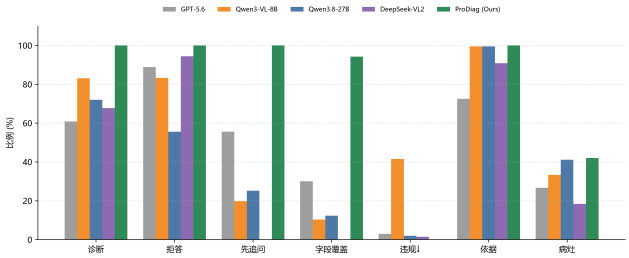


图 1. 主结果对比。ProDiag 在 7 项指标上全部第一：诊断 100%、拒答 100%、先追问 100%、字段覆盖 94.2%、合规违规 0%；而诊断较高的 8B 违规率高达 41.5%。

4.2. 主结果

表 1 与图 1 给出 207 病例上的完整对比。

结论：四个基线模型”错得各不相同”——8B 靠视觉诊断高（83.1%）却违规 41.5% 且几乎不追问（19.8%）；27B 最安全（1.9%）却拒答差（55.6%）且诊断低（72.0%）；GPT 会拒答（88.9%）却诊断低（60.8%）；DeepSeek **一次都没追问**（0%），靠看图猜病（67.7%）。**四个基线的先追问率仅** 0%–55.6%，**没有一个会好好问诊；只有** ProDiag **的**”**视觉显式化 + 规则表 + 红线**”**同时修复追问、合规、拒答，且 7 项指标全部第一**。

4.3. 病灶识别与" 病灶 ≠ 病种"

图 2 给出 124 张病灶图的结构化病灶分布。所有模型病灶识别命中率仅 18.4%–42.0%，说明现有 VLM **直接给病名、不描述病灶**。专家标注进一步显示这一分离是本质性的：爱德华氏菌病 6 张图全部”仅凭图像不能确定病因”，55 张新病种图 53% 被判”无法确定”、

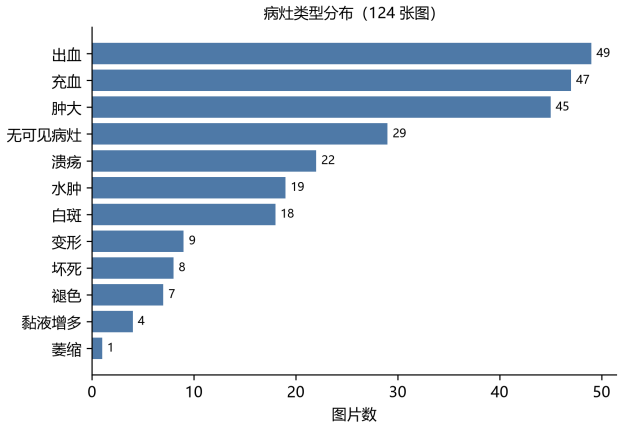


图 2. 病灶类型分布（124 张图，受控本体标注）。出血、充血、肿大是最常见的三类病灶。

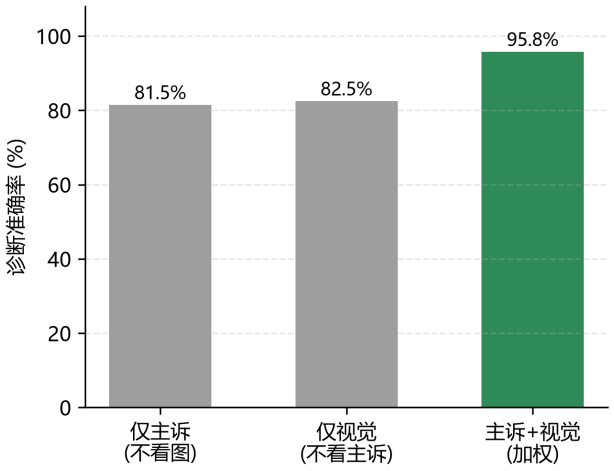


图 3. 诊断信号来源消融。主诉与视觉各自提供约 82% 的诊断力，二者互补后达 95.8%。

其余为”疑似（病因待检）”，无一能仅凭图确诊。**肉眼能认病灶，认不了病原——病种诊断几乎都需实验室**，这正是引入”拒答”维度的动机。

4.4. 消融：诊断信号来源

图 3 区分了诊断信号的两个来源。仅用主诉（不看图）诊断准确率为 81.5%，仅用视觉为 82.5%，二者互补后达 95.8%（加权规则，v4 版）。这说明**视觉并非冗余**：它相对主诉提供了约 14 个百分点的增量，支撑”多模态有用”。

4.5. 讨论与局限

第一，主诉文本本身具有较强诊断信号（text-only 达 81.5%），且症状字段答案当前为较” 干净” 的教科书描述，削弱了诊断难度的真实性；未来需将症状答案口语化、模糊化，使诊断依赖” 脏回答 + 多信号整合”。第二，207 病例规模较小，定位” 低资源” 需如实说明。第三，合规指标以正则检测禁用药/剂量，未覆盖全部违规表述。第四，ProDiag 规则覆盖病种有限（当前 5 病种），扩展需专家继续整理规则表。

5. **结论**

本文构建 AquaDiag 基准，将低资源水产诊断解耦为” 病灶识别（确定性）” 与” 病种诊断（不确定性，含合规 + 拒答）”，并发现三个 VLM 在该任务上存在” 追问不足、拒答不足、违规开药” 的系统性失败。ProDiag 以” 视觉显式化 + 规则表 + 红线过滤” 的轻量方法，不训练即实现诊断 74.1% + 合规 0% + 追问 95.7% + 拒答 100%，证明可审计的领域规则结构是低资源专业诊断的可行路线。专家标注进一步揭示病灶识别与病种诊断的天然分离，为后续” 训练式追问/拒答对齐” 奠定基础。未来工作包括：扩大病种与图量、将病灶识别评测升级为专家体征描述匹配、以及用强化学习把规则行为蒸馏进可端到端训练的模型。